Ficha de lectura

Ravishanker, N., Asha, G., & Bar, H. (2026). *Statistical Practice for Data Science.*

Referencia completa	Ravishanker, N., Asha, G., & Bar, H. (2026). *Statistical Practice for Data Science* (1ra ed.). Chapman and Hall/CRC. Capítulos 5 y 6.
Páginas, secciones o ecuaciones consultadas	Capítulos 5 y 6: Análisis de Regresión Lineal.
Problema que el autor busca resolver	Modelado de relaciones lineales entre variables predictoras y una variable de respuesta continua, estimación de parámetros (OLS) y diagnóstico exhaustivo del ajuste del modelo en contextos de ciencia de datos.
Páginas, secciones o ecuaciones consultadas	Capítulo 5: Ecuaciones de valores ajustados (5.4) y residuos (5.5) en la pág. 123; notación vector-matriz (5.17) en la pág. 133.
Problema que el autor busca resolver	Modelado de relaciones lineales entre variables predictoras y una variable de respuesta continua, estimación de parámetros (OLS) y diagnóstico exhaustivo del ajuste del modelo en contextos de ciencia de datos.
Ecuación o resultado central, en la notación del autor y en la de la clase	**Notación del autor (pág. 123 y 133):** Valor ajustado (Ec. 5.4): $\hat{Y}_i = \hat{\beta}_0 + \hat{\beta}_1 X_{i1} + ... + \hat{\beta}_p X_{ip}$ Forma vector-matriz (Ec. 5.17): $y = X\beta + \epsilon$ **Notación de la clase:** $\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\epsilon}$
Cómo se elige el parámetro de regularización, de selección o de diagnóstico, y en qué difiere de la validación cruzada	En selección de variables, criterios como AIC, BIC o el C_p de Mallows penalizan empíricamente la complejidad ajustando la verosimilitud en la muestra de entrenamiento. Por el contrario, en regularización (Ridge/Lasso), el parámetro λ se elige minimizando el error predictivo mediante validación cruzada (CV) en particiones de datos.
Afirmación del texto contrastada con evidencia propia (dataset, código, resultado) y su estatus: demostrada, evidencia numérica o heurística	**Afirmación:** La multicolinealidad infla desproporcionadamente la varianza de los estimadores OLS. **Evidencia:** Comprobado numéricamente en R usando el dataset `Hald` y `Cars93`. Al ajustar el modelo y calcular los Factores de Inflación de Varianza (VIF), variables altamente correlacionadas mostraron valores muy superiores al umbral de severidad (VIF > 10). **Estatus:** Evidencia numérica.
Limitación señalada por el texto o vigente hoy	La extrema sensibilidad de los estimadores clásicos de Mínimos Cuadrados a valores atípicos (outliers) y puntos de alto apalancamiento, además de la dependencia estricta del supuesto de homocedasticidad.
Pregunta abierta para la defensa	¿Cuál es la diferencia práctica entre un valor atípico en la variable de respuesta (outlier) y un punto de alto apalancamiento en las predictoras (leverage), y cuál representa un mayor riesgo para la estimación por Mínimos Cuadrados?