Ficha de lectura

Kuhn, M., & Johnson, K. (2013). *Applied Predictive Modeling.*

Referencia completa	Kuhn, M., & Johnson, K. (2013). *Applied Predictive Modeling.* Springer. Capítulo 6: Regresión lineal y sus variantes.
Páginas, secciones o ecuaciones consultadas	Páginas 102 a 137. Secciones 6.1 (Modelado QSAR), 6.2 (Regresión lineal), 6.3 (Mínimos cuadrados parciales - PLS), 6.4 (Modelos penalizados) y 6.5 (Informática).
Problema que el autor busca resolver	El autor aborda cómo resolver la inestabilidad matemática, la alta varianza y la imposibilidad de encontrar una solución única en la regresión lineal cuando los predictores están altamente correlacionados (colinealidad) o cuando hay más predictores que observaciones. Se busca controlar el sesgo para reducir la varianza global del modelo y minimizar el Error Cuadrático Medio (MSE).
Ecuación o resultado central	▪ Mínimos cuadrados ordinarios (OLS): $\hat{\beta} = (X^T X)^{-1} X^T y$ ▪ Regresión Ridge (Penalización L_2): $SSE_{L2} = \sum(y_i - \hat{y}_i)^2 + \lambda \sum \beta_j^2$ ▪ Lasso (Penalización L_1): $SSE_{L1} = \sum(y_i - \hat{y}_i)^2 + \lambda \sum \lvert\beta_j\rvert$ ▪ Red Elástica (Elastic Net): $SSE_{Enet} = \sum(y_i - \hat{y}_i)^2 + \lambda_1 \sum \beta_j^2 + \lambda_2 \sum \lvert\beta_j\rvert$
Cómo se elige el parámetro de regularización	Los parámetros (λ) y el número óptimo de componentes en métodos como PLS (Mínimos cuadrados parciales) se eligen sistemáticamente mediante validación cruzada repetida de 10 pliegues para minimizar el RMSE. La selección final a veces prioriza la parsimonia mediante la "regla de un error estándar". Esto significa que en lugar de elegir el parámetro que da el error mínimo exacto, nos quedamos con un modelo más simple cuyo error esté muy cerca de ese mínimo (a no más de un error estándar de distancia). Esto ayuda a evitar el sobreajuste (overfitting).".
Afirmación contrastada con evidencia propia	**Afirmación:** Lasso realiza selección de características forzando parámetros a 0, mientras que Ridge reduce los coeficientes pero los mantiene. **Evidencia propia:** Al aplicar glmnet sobre el dataset `hald` (conocido por su alta multicolinealidad), el modelo Lasso hace selección de variables y anula predictores, forzando sus coeficientes a cero y quedándose con los más relevantes. Por su parte, la regresión Ridge reduce el valor de todos los coeficientes, pero mantiene todas las variables químicas en el modelo. **Estatus:** Evidencia numérica.
Limitación señalada por el texto	La solución OLS tradicional persigue de manera excesiva las observaciones anómalas (outliers), requiriendo funciones robustas (como Huber). Además, en métodos como PLS y PCR, las nuevas variables latentes son combinaciones lineales de los predictores originales, lo que dificulta cuantificar e interpretar la contribución específica de cada variable original.
Pregunta abierta para la defensa	Si tenemos variables muy correlacionadas, ¿es mejor usar Lasso para simplificar el modelo eliminando variables, o es más seguro usar Ridge para garantizar que no perdemos ninguna información que podría ser útil?