Ficha de lectura

Ravishanker, N., Asha, G., & Bar, H. (2026). *Statistical Practice for Data Science.*

Referencia completa	Ravishanker, N., Asha, G., & Bar, H. (2026). *Statistical Practice for Data Science*. Chapman and Hall/CRC. Capítulo 6: Linear Regression – More Topics.
Páginas, secciones o ecuaciones consultadas	Páginas 146–176 del libro. Secciones 6.1 a 6.5 y ejemplos desarrollados con el conjunto de datos `deforest`. Se revisaron principalmente los códigos de preparación de datos, diagnóstico de regresión, análisis de multicolinealidad y selección de variables.
Problema que el autor busca resolver	Analizar qué variables permiten explicar los cambios en la cobertura forestal de cuatro provincias montañosas del oeste de China. Para ello, el capítulo utiliza el conjunto de datos `deforest`, con 405 observaciones y 17 variables predictoras, y presenta procedimientos de regresión lineal, diagnóstico y selección de variables mediante códigos de R.
Procedimientos y códigos de R revisados	Se revisó la lectura del archivo `deforest.csv`, la transformación de la respuesta mediante raíz cuadrada, la división de los datos en entrenamiento y prueba, y el cálculo de parámetros de centrado y escalamiento con el conjunto de entrenamiento. También se estudiaron instrucciones como `lm()`, `summary()`, `plot()`, `car::vif()`, `glmnet()`, `cv.glmnet()`, `regsubsets()` y `step()`.
Ecuación o resultado central, en la notación del autor y en la de la clase	**Notación del autor:** el modelo de regresión lineal múltiple se expresa como $Y_i = \beta_0 + \beta_1 X_{i1} + \cdots + \beta_p X_{ip} + \epsilon_i$. Para el conjunto `deforest`, la respuesta utilizada es la raíz cuadrada de la cobertura forestal: `sqrtfcover` $= \sqrt{\texttt{fcover}}$. **Notación de la clase:** $\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\epsilon}$. La aplicación de esta expresión permite relacionar la respuesta con las variables explicativas incluidas en el modelo.
Cómo se elige el parámetro de regularización, de selección o de diagnóstico, y en qué difiere de la validación cruzada	En los modelos de selección de variables, el capítulo presenta criterios como BIC, R^2 ajustado y C_p de Mallows para comparar subconjuntos de predictores. En regresión Ridge, Lasso y Elastic Net, el parámetro λ se selecciona mediante validación cruzada, utilizando el error cuadrático medio como criterio. El código del libro utiliza diez particiones mediante `nfolds = 10`. También presenta las alternativas `lambda.min` y `lambda.1se`.
Afirmación del texto contrastada con evidencia propia (dataset, código, resultado) y su estatus: demostrada, evidencia numérica o heurística	**Afirmación:** la multicolinealidad entre las variables predictoras puede afectar la estimación de los coeficientes de regresión y aumentar sus errores estándar. **Evidencia:** en el ejemplo de `deforest`, el código `car::vif(mod.1)` permite calcular los factores de inflación de varianza. El texto muestra valores superiores a 200 para las variables `temp` y `temp0`, y valores superiores a 10 para otras variables. También presenta el número de condición para evaluar la dependencia lineal entre predictores. **Estatus:** evidencia numérica presentada en el ejemplo del libro.
Limitación señalada por el texto o vigente hoy	Los procedimientos de selección pueden producir cambios en los coeficientes y sus signos según las variables incluidas en el modelo. Además, después de seleccionar variables mediante procedimientos iterativos, los valores p no deben interpretarse como si el modelo se hubiera especificado antes de observar los datos. El capítulo señala que es necesario revisar el ajuste y considerar la sensibilidad de los coeficientes ante distintas especificaciones.
Pregunta abierta para la defensa	¿Por qué es necesario separar los datos en entrenamiento y prueba antes de ajustar el modelo, y por qué los parámetros utilizados para centrar y escalar las variables deben calcularse únicamente con los datos de entrenamiento?