Ficha de lectura: Regresión por Componentes Principales (PCR)

James, G., Witten, D., Hastie, T., & Tibshirani, R. (2021). *An Introduction to Statistical Learning.*

Referencia completa	James, G., Witten, D., Hastie, T., & Tibshirani, R. (2021). *An Introduction to Statistical Learning: with Applications in R.* 2nd Edition. Springer. Sección 6.3.1: Principal Components Regression, pp. 251–259.
Páginas, secciones o ecuaciones consultadas	Páginas 251 a 259. Sección 6.3.1 (Principal Components Regression) y Sección 6.5.3 (Lab: PCR and PLS Regression).
Problema que el autor busca resolver	Abordar los problemas de alta dimensionalidad ($p > n$) y multicolinealidad en regresión lineal. Se busca proyectar los p predictores originales en un subespacio de menor dimensión $M < p$ para reducir drásticamente la varianza del modelo y evitar el sobreajuste (overfitting).
Ecuación o resultado central	▪ Transformación PCA (Componentes latentes): $Z_m = \sum_{j=1}^{p} \phi_{jm} X_j$ para $m = 1, \ldots, M$ ▪ Regresión sobre componentes (OLS): $y_i = \theta_0 + \sum_{m=1}^{M} \theta_m z_{im} + \epsilon_i$ ▪ Coeficientes equivalentes en X: $\beta_j = \sum_{m=1}^{M} \theta_m \phi_{jm}$
Cómo se elige el parámetro de regularización	El número óptimo de componentes principales M se elige mediante validación cruzada ($k = 10$ folds) evaluando el error cuadrático medio de predicción (MSEP). Se suele aplicar la regla de un error estándar para seleccionar el menor número de componentes M cuyo error se encuentre a no más de 1 SE del mínimo.
Afirmación contrastada con evidencia propia	**Afirmación:** PCR reduce dimensiones usando combinaciones lineales de los predictores, pero NO realiza selección de variables (mantiene todas las variables originales representadas en las componentes). **Evidencia propia:** Al aplicar `pcr()` de la librería `pls` sobre los datasets `hald` y `Cars93`, las componentes principales retienen información de todas las variables originales, a diferencia de Lasso que fuerza coeficientes a 0. **Estatus:** Evidencia numérica.
Limitación señalada por el texto	PCR es un método no supervisado: la creación de componentes principales maximiza la varianza entre las variables predictoras X, sin considerar la variable respuesta Y. Por ende, las componentes principales no garantizan ser las más asociadas con la respuesta.
Pregunta abierta para la defensa	Si los primeros componentes principales no contienen la mayor variabilidad explicativa sobre la variable respuesta Y, ¿es mejor optar por Partial Least Squares (PLS) que sí supervisa la creación de componentes con Y?