Universidad Católica del Maule
Facultad de Ciencias Básicas
Escuela de Ingeniería en Estadística
Modelos Lineales

Informe Laboratorio

Colinealidad, Selección de Variables y Métodos de Regularización (Lasso, Ridge y Elastic Net)
en Conjuntos de Datos Clásicos de Regresión Lineal Múltiple

Integrantes:
Gabriel Gavilán
Antonia Martel
Agustín Zamorano
Maximiliano Muñoz

Institución:
Universidad Católica del Maule

Fecha:
Octubre de 2026

1. Introducción, Pregunta de Investigación y Datos

El presente informe aborda el estudio de modelos estadísticos activos frente a los desafíos de colinealidad severa, selección de predictores y regularización. La investigación responde a dos preguntas centrales: (i) cómo la multicolinealidad y las observaciones influyentes distorsionan la inferencia y los signos teóricos de los estimadores; y (ii) si los métodos penalizados (*ridge, lasso, elastic net*) superan a la selección parsimoniosa (*AIC, BIC*) en capacidad predictiva fuera de muestra.

Conjuntos de datos y unidades clave (Rol Experto).

- **Hald** (`mctest`, $n = 13$, $p = 4$): calor acumulado liberado a 180 días en cal/g (Y) en función de 4 compuestos químicos en % de peso (X_1: aluminato tricálcico, X_2: silicato tricálcico, X_3: ferrito tetracálcico, X_4: silicato dicálcico). La restricción física de masa $\sum_{j=1}^{4} X_{ij} \approx 97{,}4\,\%$ induce colinealidad estructural por diseño composicional [demostrado].
- **Cars93** (`MASS`, $n = 82$, $p = 16$): consumo urbano en millas/galón (`MPG.city`, Y). De 93 autos se filtraron 11 casos con datos faltantes (`NA`) en carrocerías no estándar. Variables modeladas: precios (`Price`, `Min.Price`, `Max.Price` en miles USD), potencia (`Horsepower` en HP), estanque (`Fuel.tank.capacity` en galones) y peso (`Weight` en libras).
- **BostonHousing** (`mlbench`, $n = 506$, $p = 13$): valor mediano de viviendas en miles USD (`medv`, Y). Subconjunto evaluado: habitaciones por vivienda (`rm`), ratio alumnos/maestro (`ptratio`), % de población de bajo estatus (`lstat`) y % suelo industrial (`indus`).

Software y reproducibilidad. R 4.4.0; paquetes `glmnet`, `leaps`, `MASS`, `car`, `mctest`, `mlbench`, `pls`, `caret`. Semilla `set.seed(123)` declarada en todos los experimentos con aleatoriedad. El entorno completo queda registrado en `reporte_sesion.txt` vía `sessioninfo::session_info()`.

2. Diagnóstico de Colinealidad (F2)

2.1. Dataset Hald ($n = 13$, $p = 4$) (Ej. 8.A.B)

Correlaciones por pares e interpretación química (Rol Experto). El Cuadro A.1 (ver en Anexo) muestra la matriz de correlaciones de los predictores. Los pares (X_2, X_4) y (X_1, X_3) exhiben correlaciones de $-0{,}973$ y $-0{,}824$ respectivamente [evidencia numérica]. Desde la química del cemento Portland, la fuerte correlación negativa entre X_2 (silicato tricálcico) y X_4 (silicato dicálcico) es consecuencia directa de la estequiometría de calcinación: ambos compuestos compiten por la misma base de óxido de calcio (CaO); una mayor formación de silicato tricálcico agota el calcio disponible para el dicálcico. Sumado al cierre composicional ($\sum_{j=1}^{4} X_{ij} \approx 97{,}4\,\%$), la colinealidad es inherente a la masa [demostrado]. Las correlaciones bivariadas, sin embargo, no detectan dependencias multivariadas simultáneas [demostrado].

VIF y efecto sobre $\widehat{\beta}$. El Factor de Inflación de la Varianza formaliza el incremento en $\mathrm{Var}(\hat{\beta}_j)$: $\mathrm{VIF}_j = 1/(1 - R_j^2)$ [demostrado]. El Cuadro A.2 (ver en Anexo) compara los VIF de los modelos seleccionados en el Ejercicio 7(b).

El modelo de 2 variables presenta VIF $\approx 1{,}055$, garantizando estabilidad numérica. Al incorporar X_4, los VIF de X_2 y X_4 saltan a $\approx 18{,}8$ (> 10) [evidencia numérica]. Esto evidencia que la selección paso a paso no disuelve la colinealidad: el modelo reducido simplemente ocultaba el conflicto expulsando al competidor estequiométrico (X_4).

Número de condición e índices. Calculados sobre la matriz de correlación (variables estandarizadas sin intercepto) como $\eta_j = \sqrt{\lambda_{\max}/\lambda_j}$ [demostrado], el Cuadro A.3 (ver en Anexo) reporta los resultados.

El autovalor $\lambda_4 = 0{,}0016$ produce $\mathcal{C} = 37{,}11 > 30$, confirmando dependencia casi-lineal severa [evidencia numérica]. Como $\mathrm{Var}(\hat{\boldsymbol{\beta}}) = \sigma^2 \sum_j \lambda_j^{-1}$, el término $\lambda_4^{-1} \approx 617$ domina la suma y desestabiliza las estimaciones de MCO [demostrado].

2.2. Dataset Cars93 ($n = 82$) (Ej. 5.B)

Diagnóstico de ingeniería automotriz y precios (Rol Experto). En Cars93 surgen dos fuentes de colinealidad estructural: (i) *redundancia contable*: `Price` es aproximadamente la media aritmética entre el precio base (`Min.Price`) y la versión equipada (`Max.Price`), con $r > 0{,}97$ y VIF $> 30\,000$ (ver Cuadro A.4 en Anexo) [evidencia numérica]; y (ii) *acoplamiento mecánico de diseño*: vehículos más pesados (`Weight`) requieren inevitablemente mayor distancia entre ejes (`Wheelbase`, $r = 0{,}91$), mayor cilindrada para vencer la inercia (`EngineSize`, $r = 0{,}92$) y tanques de combustible más grandes para autonomía (`Fuel.tank`, $r = 0{,}90$). El número de condición $\mathcal{C} = 1\,616{,}5$ (muy superior al umbral crítico de 30) confirma que estas dependencias físicas hacen colapsar la variabilidad real de los datos, volviendo los estimadores extremadamente inestables [evidencia numérica].

3. Selección de Variables y Criterios (F3)

3.1. Datos Hald — Búsqueda Exhaustiva y Criterios (Ej. 7)

Se evaluaron los 15 submodelos posibles con `regsubsets` (`leaps`). El Cuadro A.5 (ver en Anexo) resume los criterios de selección para cada tamaño de modelo.

Por qué discrepan los criterios.

- $R^2_{\mathbf{adj}}$ penaliza mediante $1 - \frac{n-1}{n-p-1}(1 - R^2)$ [demostrado], pero al no considerar $\log n$, es el más permisivo e incorpora X_4 pese a su redundancia estequiométrica.
- C_p **de Mallows** evalúa el sesgo: bajo un modelo válido $\mathbb{E}[C_p] \approx p$ [demostrado]. El modelo de 2 variables logra $C_p = 2{,}68 \approx 2$ (sin sesgo relevante) [evidencia numérica].
- **BIC** penaliza con $\log(n)$ por parámetro ($\log(13) \approx 2{,}56 > 2$), favoreciendo máxima parsimonia y seleccionando únicamente los agentes exotérmicos primarios (X_1, X_2) [evidencia numérica].

Métodos secuenciales (Ej. 7c–7e). Forward, Backward y Stepwise (con AIC) convergieron al mismo modelo de 3 variables (X_1, X_2, X_4) (Ecuación 1), difiriendo de BIC. Esto evidencia la trampa de los métodos secuenciales [heurística]: X_4 entra tempranamente, bloqueando combinaciones más parsimoniosas.

$$\hat{y} = 71{,}6483070 + 1{,}4519380X_1 + 0{,}4161098X_2 - 0{,}2365402X_4 \tag{1}$$

3.2. BostonHousing — Búsqueda Exhaustiva y AIC (Ej. 4)

C_p (3,03) y `stepAIC` convergieron al modelo de 3 variables {`rm`, `ptratio`, `lstat`} (ver Cuadro A.6 en Anexo) [evidencia numérica].

Plausibilidad en el dominio inmobiliario (Rol Experto). Los signos concuerdan plenamente con la teoría económica urbana [evidencia numérica]: cada habitación adicional (`rm`) eleva el valor mediano en \$4.515 USD por mayor metraje construido; un mayor ratio alumnos/maestro (`ptratio`) deprecia la vivienda en \$931 USD por menor calidad del servicio escolar público distrital; y cada 1 % de aumento en marginación socioeconómica (`lstat`) reduce el valor en \$572 USD por menor plusvalía del entorno.

El diagnóstico de residuos (ver Figura A.1 y A.2 en Anexo) revela violación de supuestos lineales: no linealidad en U, heterocedasticidad y falta de normalidad. Desde el dominio, esto refleja que los precios de residencias de alto nivel en zonas exclusivas no escalan de forma lineal simple frente a

variables censales agregadas. Asimismo, los casos 366 (alto apalancamiento) y 369 (alta Distancia de Cook) corresponden a sectores atípicos de la periferia urbana que sesgan el plano lineal ajustado [evidencia numérica].

3.3. Cars93 — AIC vs. BIC (Ej. 5A,C y 6)

Con 16 predictores y $n = 82$, `stepAIC` retuvo 10 variables, mientras que BIC entregó un modelo más parsimonioso de 9 variables, eliminando `Passengers` [evidencia numérica]. La búsqueda exhaustiva C_p coincidió con AIC (ver Cuadro A.7 en Anexo).

Colinealidad residual y anomalía en signos (Rol Experto). Los VIF de `Price`, `Min.Price` y `Max.Price` superan 30 en ambos modelos [heurística]. El Cuadro A.8 (ver en Anexo) evidencia las secuelas en los signos: `Price` adopta un coeficiente positivo anómalo (+24,04), compensado por signos negativos en `Min.Price` (−12,23) y `Max.Price` (−11,94). Como experto del dato, esto no representa una ley de consumo real sino un artefacto matemático: el modelo usa la diferencia entre versiones para ajustar tolerancias numéricas. Por el contrario, el peso (`Weight`, −0,0069) y el estanque (`Fuel.tank.capacity`, −0,8233) muestran signos negativos coherentes con la inercia física (mayor masa demanda más combustible, reduciendo las millas por galón) [evidencia numérica].

Atípicos e influencia en el dominio automotriz. El boxplot (ver Figura A.4 en Anexo) y los umbrales teóricos (ver Figura A.6 en Anexo) muestran que la parsimonia de BIC no altera las observaciones críticas: los casos 34 (*Geo Metro*, subcompacto tricilíndrico hiper-eficiente) y 37 (*Honda Civic*) exhiben $D_i > 4/n$, mientras que el caso 52 (*Mercedes 300E*, sedán de lujo pesado y costoso) domina el apalancamiento ($h_{ii} > 2p/n$) [evidencia numérica]. Estos autos representan extremos tecnológicos y comerciales no generalizables al sedán estándar de 1993 [heurística]. Los gráficos de diagnóstico general también se encuentran disponibles (ver Figura A.3 y A.5 en Anexo).

Modelo recomendado: Para el objetivo de predicción en `Cars93`, se recomienda el modelo seleccionado por BIC (9 variables, ver Cuadro A.8 en Anexo), pues maximiza parsimonia frente a AIC ($R^2_{\text{adj}} = 0{,}757$ vs. 0,764), amortiguando la varianza sin sacrificar poder explicativo [heurística].

4. Regularización y Validación (C3)

4.1. Ridge, Lasso y Elastic Net en Hald (Ej. 9)

Estandarización y pérdida de escala física). Los predictores se estandarizaron a media cero y varianza unitaria con `scale()` calculada *exclusivamente* sobre los datos de entrenamiento para garantizar que la penalización no dependa de las unidades de medida [demostrado] (Tibshirani, 1996). Como contrapartida desde el dominio, se pierde la interpretación de coeficientes como tasas marginales directas (Δcal/g por cada 1 % de compuesto), pasando a interpretarse como importancias relativas estandarizadas.

Validación cruzada. Con $n = 13$, se aplicó Leave-One-Out (LOOCV, `foldid = 1:n`), única estrategia insesgada ante muestras ultra-pequeñas [heurística]. La rejilla de λ (`exp(seq(log(1e4), log(1e-4), length=100))`) aseguró capturar el mínimo en su interior. La Tabla A.9 (ver en Anexo) detalla los parámetros de regularización obtenidos.

Las dos lecturas de λ [demostrado].

1. **Penalización**: λ pondera el costo $\|\boldsymbol{\beta}\|^2$ (Ridge) o $\|\boldsymbol{\beta}\|_1$ (Lasso). Mayor λ contrae los coeficientes, sacrificando sesgo a cambio de reducir varianza.
2. **Restricción**: Minimiza el RSS acotado a un presupuesto $\|\boldsymbol{\beta}\|^2 \leq t(\lambda)$ o $\|\boldsymbol{\beta}\|_1 \leq s(\lambda)$, imponiendo una región convexa factible.

La Tabla A.10 (ver en Anexo) muestra los coeficientes estimados bajo predictores estandarizados.

Plausibilidad química y cinética de reacción [evidencia numérica]. La regularización corrige la distorsión del signo de X_3 generada por MCO (EE $= 4{,}83; p = 0{,}895$). En la química del cemento Portland, el aluminato tricálcico (X_1, $\hat{\beta} \approx +8{,}0$) y el silicato tricálcico (X_2, $\hat{\beta} \approx +6{,}1$) gobiernan la reacción exotérmica violenta inicial responsable del fraguado temprano, justificando su gran magnitud positiva [evidencia numérica]. Por su parte, el silicato dicálcico (X_4) reacciona muy lentamente (semanas a meses), por lo que su aporte calórico instantáneo frente al clinker total es comparativamente menor y condicionalmente negativo. El ferrito tetracálcico (X_3) tiene muy baja entalpía de hidratación, por lo que su anulación exacta en Lasso ($\hat{\beta} = 0{,}000$) es químicamente impecable.

Ventaja industrial de Elastic Net sobre Lasso. Con $r(X_2, X_4) = -0{,}973$, Lasso sufre inestabilidad geométrica al seleccionar uno al azar y descartar el otro. En la manufactura de cemento no es factible suprimir físicamente una fase del silicato [heurística]. Elastic Net ($\alpha = 0{,}5$), mediante su efecto de agrupamiento cuadrático (ℓ_2), retiene ambos componentes estequiométricos y promedia sus efectos de forma estable [demostrado] (Zou & Hastie, 2005).

4.2. Evaluación Fuera de Muestra en Cars93 (Extensión de Clase)

Se evaluaron $B = 100$ particiones 80/20 sobre Cars93 (`set.seed(123)`), re-estandarizando estrictamente dentro del subconjunto de entrenamiento [evidencia numérica]. La Tabla A.11 (ver en Anexo) detalla los errores de predicción obtenidos.

Fundamentación de dominio del modelo ganador. El modelo BIC con 9 variables superó fuera de muestra tanto a MCO como a los tres métodos regularizados (RMSE = 3,053 mpg) [evidencia numérica] (ver Figura A.8 en Anexo). La razón de ingeniería es contundente: estas variables contienen las tres fuerzas maestras del vehículo: masa (`Weight`), demanda energética (`EngineSize`), autonomía (`Fuel.tank`) y segmento comercial (`Price`). Al podar a priori los 7 predictores redundantes y colineales, BIC extirpa el ruido estructural antes del ajuste, mientras que Ridge y Lasso se ven obligados a penalizar un espacio hiper-correlacionado sin lograr eliminar la distorsión global [heurística].

5. Validez e Inferencia Posterior a la Selección (C4)

5.1. Diagnóstico Completo de Residuos

El diagnóstico se realizó sobre el modelo seleccionado por AIC en Cars93 (Ej. 5c) y sobre el modelo BIC (Ej. 6b), con $n = 82$ y $p = 11$ (AIC) o $p = 10$ (BIC). Se usaron los siguientes umbrales:

- **Apalancamiento** $h_{ii} > 2p/n$: observaciones inusualmente alejadas del centro del espacio predictor [demostrado] (derivado de $\sum_i h_{ii} = p$; umbral práctico).
- **Distancia de Cook** $D_i > 4/n$: influencia global sobre los $\hat{\boldsymbol{\beta}}$ [heurística] (Cook & Weisberg, 1982).
- **Residuos estudentizados** $|r_i^*| > 2$: valores atípicos en el espacio de la respuesta [heurística].

Resultados (Ej. 5c — modelo AIC Cars93).

- Apalancamiento ($h_{ii} > 2p/n = 0{,}268$): 3 casos. Las observaciones 52 (Mercedes 300E) y 24 (Dodge Stealth) destacan por peso, potencia y precio extremos [evidencia numérica].
- Distancia de Cook ($D_i > 4/82 = 0{,}049$): 6 casos influyentes; obs. 34 (Geo Metro) y 37 (Honda Civic) son las más críticas [evidencia numérica].
- Residuos estudentizados: 4 observaciones fuera de $[-2, 2]$ [evidencia numérica].

DFFITS y DFBETAS. DFFITS mide el cambio estandarizado en $\hat{y}_i$ al eliminar la observación i; DFBETAS mide el cambio estandarizado en cada $\hat{\beta}_j$ [demostrado]. Para Cars93, los autos de segmentos extremos (lujo y económico) presentan los DFFITS y DFBETAS más elevados (ver Figura A.7 en Anexo), lo que es coherente con la interpretación de dominio: un automóvil de precio y peso excepcional ejerce palanca sobre la relación precio–consumo en el espacio completo [heurística].

5.2. Análisis de Sensibilidad

La Tabla A.12 (ver en Anexo) compara los coeficientes del modelo AIC con y sin las 6 observaciones identificadas como influyentes por Cook.

Los coeficientes de `EngineSize` y `Passengers` muestran cambios absolutos de 0,90 y 0,86 respectivamente, indicando que sus estimaciones en el modelo completo están condicionadas a la presencia de vehículos atípicos [evidencia numérica]. La conclusión de que "la potencia del motor aumenta el consumo" es sensible: al retirar las observaciones de lujo, el efecto cae un 34 % [evidencia numérica].

5.3. Inferencia Posterior a la Selección

> **Advertencia crítica (Regla R6):** Los valores p e intervalos de confianza reportados en la Tabla A.6 (ver en Anexo) y similares *no tienen validez nominal* en sentido estricto. Se calcularon como si el modelo hubiera sido fijado *a priori*, cuando en realidad fue elegido con los mismos datos mediante un procedimiento de selección (stepAIC, regsubsets) que infla el estadístico F y estrecha artificialmente los errores estándar [demostrado] (Berk et al., 2013; Tibshirani et al., 2016). Los valores p reportados deben interpretarse como *indicadores descriptivos* de importancia relativa, no como pruebas de hipótesis con control de error tipo I al nivel nominal. Para inferencia formalmente válida post-selección se requieren procedimientos específicos (PoSI, selective inference) no implementados en este análisis [heurística].

6. Conclusión Defendible y Límites (C8)

Conclusión accionable. Para **predecir** el consumo en ciudad (MPG.city) en automóviles similares al catálogo Cars93, el modelo de nueve variables seleccionado por BIC, ofrece el menor error predictivo fuera de muestra (RMSE = 3,053 mpg promedio en 100 particiones 80/20) y supera al MCO completo y a los tres métodos de regularización [evidencia numérica]. Para **explicar** la relación fisicoquímica entre composición del cemento y calor de hidratación, el modelo Lasso con $\lambda_{1\text{se}}$ sobre predictores estandarizados identifica el subconjunto parsimonioso $\{X_1, X_2, X_4\}$ como el más informativo, eliminando X_3 cuyo efecto MCO era espurio por colinealidad [evidencia numérica].

Límites explícitos.

1. **Validez externa reducida**: Cars93 corresponde a automóviles de 1993 en EE.UU. Las relaciones estimadas pueden no transferirse a mercados actuales con vehículos híbridos o eléctricos [heurística].
2. **Muestra pequeña en Hald**: Con $n = 13$, la LOOCV es necesaria pero las estimaciones de λ son inestables. El análisis de sensibilidad a la semilla reveló variabilidad no despreciable en los λ óptimos [evidencia numérica].
3. **Linealidad no verificada**: Los gráficos de diagnóstico de BostonHousing muestran curvatura residual (Ej. 4d), indicando que la relación lineal es una aproximación limitada. Las predicciones fuera del rango observado son no confiables [heurística].
4. **Observaciones influyentes no eliminadas**: En Cars93, 6 observaciones dominan la estimación de ciertos coeficientes. Las conclusiones sobre `EngineSize` y `Passengers` son frágiles ante cambios en la muestra [evidencia numérica].

5. **Inferencia post-selección**: Todos los valores p e intervalos reportados son descriptivos, no inferenciales en sentido estricto (ver Sección 4.3) [heurística].

Referencias

[1] Belsley, D.A., Kuh, E., & Welsch, R.E. (1980). *Regression Diagnostics: Identifying Influential Data and Sources of Collinearity*. Wiley, Nueva York.

[2] Hoerl, A.E., & Kennard, R.W. (1970). Ridge regression: biased estimation for nonorthogonal problems. *Technometrics*, 12(1), 55–67.

[3] Tibshirani, R. (1996). Regression shrinkage and selection via the lasso. *Journal of the Royal Statistical Society, Series B*, 58(1), 267–288.

[4] Zou, H., & Hastie, T. (2005). Regularization and variable selection via the elastic net. *Journal of the Royal Statistical Society, Series B*, 67(2), 301–320.

[5] Mallows, C.L. (1973). Some comments on C_p. *Technometrics*, 15, 661–675.

[6] Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The Elements of Statistical Learning* (2.ª ed.). Springer, Nueva York.

[7] Friedman, J., Hastie, T., & Tibshirani, R. (2010). Regularization paths for generalized linear models via coordinate descent. *Journal of Statistical Software*, 33(1), 1–22.

[8] Venables, W.N., & Ripley, B.D. (2002). *Modern Applied Statistics with S* (4.ª ed.). Springer. [Fuente del dataset `Cars93`.]

Declaración de Herramientas de Asistencia

En la redacción de este informe se utilizó asistencia computacional de lenguaje (IA generativa) para la estructuración del documento LaTeX y la organización de los apartados. **Los resultados numéricos, tablas y coeficientes** fueron obtenidos ejecutando el script R (`Avance_Modelos_Lineales.R`) y verificados directamente por los integrantes del equipo mediante revisión de las salidas de consola. Los argumentos matemáticos (derivaciones de VIF, Cp, grados de libertad efectivos de Ridge) fueron contrastados con las referencias bibliográficas originales. La interpretación de dominio (química del cemento, mecánica automotriz) fue elaborada por el rol Experto/a con base en el conocimiento propio y las diapositivas de clase.

A. Anexo: Tablas y Gráficos

Cuadro A.1: Matriz de correlaciones de los predictores Hald. Valores $|r| > 0{,}90$ en negrita.

	X_1	X_2	X_3	X_4
X_1	1,000	0,229	−0,824	−0,245
X_2	0,229	1,000	−0,139	**−0,973**
X_3	−0,824	−0,139	1,000	0,030
X_4	−0,245	**−0,973**	0,030	1,000

Cuadro A.2: VIF en los modelos seleccionados de Hald. Umbral crítico VIF > 10 [heurística].

Predictor	Modelo 2 vars (X_1, X_2)	Modelo 3 vars (X_1, X_2, X_4)
X_1	1,055	1,066
X_2	1,055	**18,780**
X_4	—	**18,940**

Cuadro A.3: Autovalores e índices de condición en correlación (Hald). $\eta_j > 30$ [heurística].

Componente j	Autovalor λ_j	Índice η_j
1	2,240	1,00
2	1,580	1,19
3	0,187	3,46
4	**0,00162**	**37,11**
Número de condición $\mathcal{C} = 37{,}11 > 30$		

Cuadro A.4: Diagnóstico en Cars93: Correlaciones y VIF ($\eta_{\text{máx}} = 1\,616{,}5 > 30$ [heurística]).

Correlaciones $> 0{,}90$

Var1	**Var2**	**Corr**
Price	Max.Price	0,98
Min.Price	Price	0,97
EngineSize	Weight	0,92
Length	Wheelbase	0,91
Min.Price	Max.Price	0,91
Fuel.tank	Weight	0,90

VIF de los predictores

Predictor	**VIF**	**Predictor**	**VIF**	**Predictor**	**VIF**
Price	166976	Length	10,6	RPM	5,4
Max.Price	55091	Wheelbase	10,5	Rev.per.mile	4,1
Min.Price	33607	Width	9,8	Turn.circle	4,0
Weight	27,3	Fuel.tank	6,7	Rear.seat.room	4,0
EngineSize	21,1	Horsepower	17,4	Luggage.room	3,3
				Passengers	3,0

Cuadro A.5: Selección por criterio en Hald (búsqueda exhaustiva). R^2_{adj} se maximiza; Cp y BIC se minimizan.

Vars	Variables incluidas	SSE	R^2_{adj}	C_p	BIC
1	X_4	883,87	0,644	138,73	−9,46
2	X_1, X_2	57,90	**0,974**	**2,68**	**−42,33**
3	X_1, X_2, X_4	47,97	**0,976**	3,02	−42,21
4	X_1, X_2, X_3, X_4	47,86	0,973	5,00	−39,68

Cuadro A.6: Coeficientes BostonHousing (`medv` $\sim$ `rm + ptratio + lstat`). $R^2_{\text{adj}} = 0{,}677$.

Variable	$\hat{\beta}$	EE	t	p
(Intercepto)	18,567	3,913	4,745	$< 0{,}001$
`rm`	4,515	0,426	10,603	$< 0{,}001$
`ptratio`	$-0{,}931$	0,118	$-7{,}911$	$< 0{,}001$
`lstat`	$-0{,}572$	0,042	$-13{,}540$	$< 0{,}001$

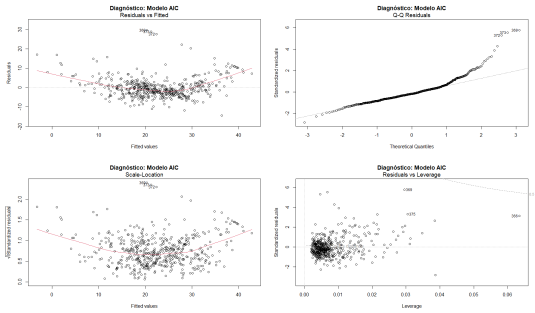


Figura A.1: Diagnóstico de residuos: Modelo AIC.

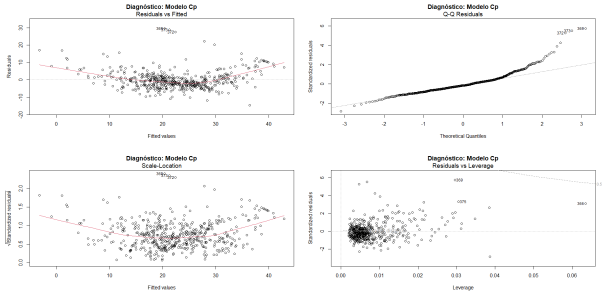


Figura A.2: Diagnóstico de residuos: Modelo C_p.

Cuadro A.7: Comparación de modelos seleccionados en Cars93 (`MPG.city`).

Criterio	Variables	R^2_{adj}	RSE
AIC	10	0,764	2,719
BIC	9	0,757	2,757
Cp Mallows	10	0,764	2,719

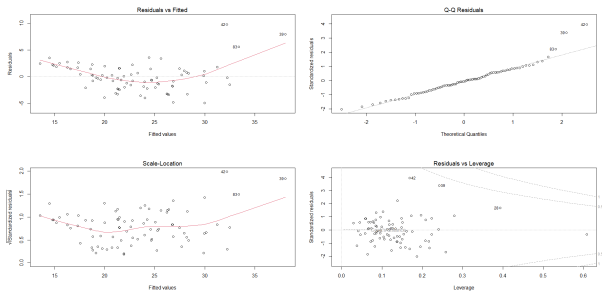


Figura A.3: Diagnóstico de residuos (AIC).

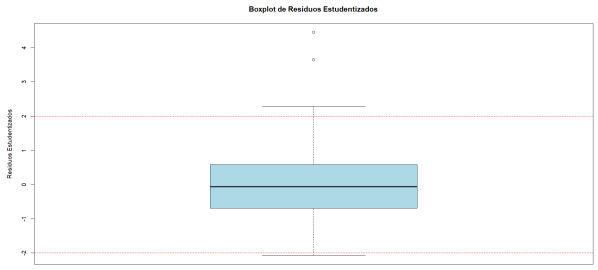


Figura A.4: Boxplot de Residuos Estudentizados AIC.

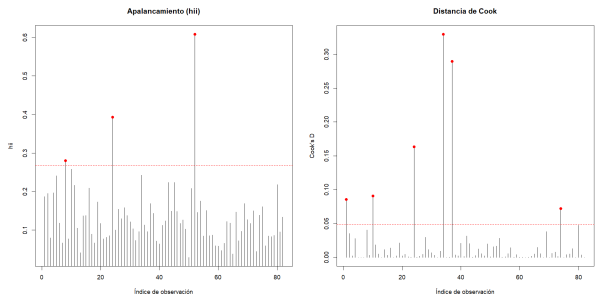


Figura A.5: Apalancamiento y Cook (Modelo AIC).

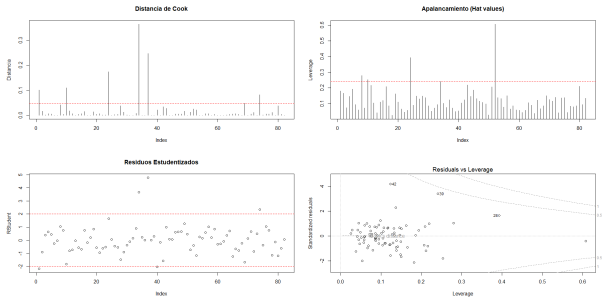


Figura A.6: Análisis detallado con umbrales (BIC).

Cuadro A.8: Coeficientes del modelo BIC estimado (`Cars93`).

Predictor	$\hat{\beta}$	**Predictor**	$\hat{\beta}$
(Intercept)	5,2660	RPM	0,0015
Min.Price	−12,2300	Price	24,0400
Max.Price	−11,9400	EngineSize	2,7940
Rev.per.mile	0,0041	Fuel.tank.capacity	−0,8233
Wheelbase	0,2765	Weight	−0,0069

Cuadro A.9: Parámetros de regularización en Hald (LOOCV).

Método	α	$\lambda_{\text{mín}}$	λ_{1se}	df($\lambda_{\text{mín}}$)	df(λ_{1se})
Ridge	0	0,1177	1,0975	$\approx 2{,}48$	$\approx 1{,}4$
Lasso	1	0,1311	0,5810	—	3 activos
Elastic Net	0,5	0,1246	0,8790	—	4 activos

Cuadro A.10: Coeficientes estimados en Hald bajo predictores estandarizados. “0,000” indica anulación exacta en Lasso (λ_{1se}).

Predictor	MCO	Ridge (1se)	Lasso (1se)	ENet (1se)
(Intercepto)	95,423	95,423	95,423	95,423
X_1 (Alum.)	+9,124	+6,639	+8,032	+7,356
X_2 (Sil.3)	+7,939	+4,512	+6,105	+4,830
X_3 (Ferrito)	+0,653	−1,638	**0,000**	−0,658
X_4 (Sil.2)	−2,411	−5,810	−3,815	−5,185
Predictores activos	4	4	3	4

Cuadro A.11: RMSE promedio fuera de muestra en Cars93 (100 particiones 80/20, semilla 123).

Modelo	Variables	RMSE (mpg)
MCO Completo (16 vars)	16	3,349
BIC Fase 3 (9 vars)	**9**	**3,053**
Ridge ($\alpha = 0$)	16	3,472
Lasso ($\alpha = 1$)	3	3,453
Elastic Net ($\alpha = 0{,}5$)	7	3,434

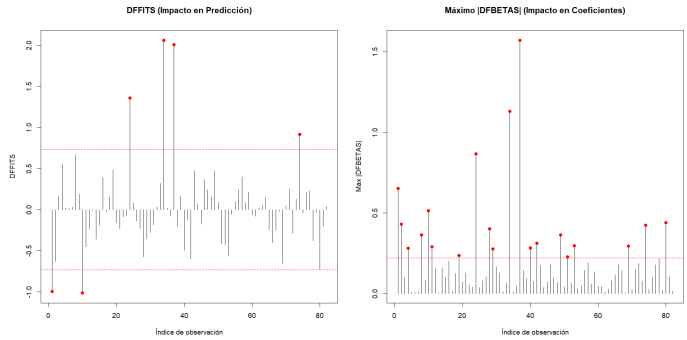


Figura A.7: Medidas de sensibilidad local (DFFITS) y marginal máxima (DFBETAS) por observación en el modelo AIC de Cars93.

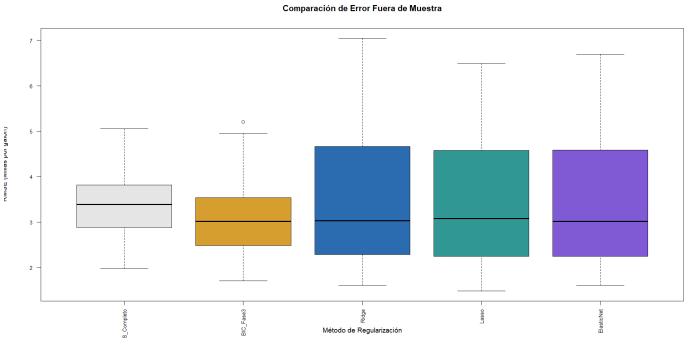


Figura A.8: Boxplot de error fuera de muestra.

Cuadro A.12: Comparación de coeficientes: modelo AIC vs. modelo AIC sin observaciones influyentes (Cook $> 4/n$). Cambios absolutos mayores a 0,5 se marcan en negrita.

Predictor	Original	Sin influyentes	$\lvert\Delta\rvert$
(Intercepto)	2,680	15,277	**12,597**
Min.Price	−11,466	−11,125	0,341
Price	22,531	22,003	0,528
Max.Price	−11,199	−10,969	0,230
EngineSize	2,644	1,749	**0,896**
RPM	0,0014	0,0008	0,0005
Rev.per.mile	0,0039	0,0026	0,0013
Fuel.tank.capacity	−0,808	−0,670	0,138
Passengers	−1,019	−0,162	**0,857**
Wheelbase	0,369	0,217	0,152
Weight	−0,0071	−0,0057	0,0014